Иван Лебедев

Python-разработчик — AI/LLM Engineer, Backend

Санкт-Петербург +7 910 856-43-23 vanyalebedev45@gmail.com t.me/n1xs1 github.com/n1xsi

Обо мне

Python-разработчик с 10 месяцами практического опыта: 6 месяцев коммерческой разработки в Nexign (AI-Group) и 4 месяца производственной практики. Специализация — LLM-сервисы и бэкенд к ним: RAG-поиск, self-hosted инференс, обезличивание ПДн для работы моделей в закрытом контуре.

Результаты: автоматизировал подготовку ПМИ в отделе из 32 инженеров (−60% времени на комплект); вывел в прод асинхронный сервис, которым ежедневно пользуются 100+ студентов. Понимаю системный уровень (C/C++, Assembler, Linux).

Ищу роль AI/LLM Engineer или Python-backend. Студент 4 курса ГУАП, **готов к полной занятости**.

Опыт работы

Nexign, Python-разработчик, AI-Group (Срочный контракт, команда 8 чел.) *Апр 2026 – Сент 2026*

- Разработал RAG-пайплайн поиска по корпоративной базе (2 тыс. документов, 50 тыс. чанков): эмбеддинги (BAAI/bge-m3), векторный поиск в Qdrant и pgvector, ранжирование. FastAPI-сервис в Docker: p95 — 190 мс, recall@5 — 86%. Пользуются 240 сотрудников.
- Реализовал сервис обратимой анонимизации ПДн (152-ФЗ) перед отправкой в LLM: 10+ типов сущностей (телефон, СНИЛС, ИНН, номера карт) через регулярные выражения и контрольные суммы, подстановка токенов и демаскинг в ответе. Точность детекции F1=89% на тестовой выборке из 200 документов — это разблокировало работу LLM с внутренними документами.
- Автоматизировал генерацию ПМИ: перевёл пайплайн с LangChain-скриптов на n8n. Ускорил подготовку тестов с 40 мин. до 15 мин. (-60%); решением пользуются 32 инженера отдела.
- Развернул self-hosted инференс LLM (Qwen2.5-32B-Instruct, 2×NVIDIA A100 80GB) на vLLM и Triton: настроил continuous batching, квантизацию и health-checks, выжал 500+ токенов/с. Корпоративные документы перестали уходить во внешний API.
- Стабилизировал сервис распознавания речи (обвязка над внешней ASR-моделью): закрыл десятки критичных багов, поднял покрытие тестами с 20% до 80% (pytest, unit и smoke).

FutureToday, Python-разработчик (Производственная практика, команда 3 чел.) *Февр 2025 – Май 2025*

- Реализовал модуль семантического поиска стажировок с фильтрацией вакансий по стеку (Python, sentence-transformers, scikit-learn). Ускорил обработку Excel-выгрузок кандидатов (файлы по 30+ тыс. строк) с 20 минут до 10 минут за счёт перехода с построчной итерации openpyxl на векторизованные операции pandas и потоковое чтение.
- Перевёл 4 Telegram-бота карьерных мероприятий с no-code конструкторов на собственную асинхронную реализацию (Python, aiogram, FSM): убрал зависимость от сторонних платных сервисов и связал сбор откликов напрямую с внутренней БД.

Образование

Бак. **ГУАП**, Информатика и вычислительная техника (09.03.01) *Сент 2023 – Июнь 2027*

- Диплом и научные статьи по применению нейросетей в разработке ПО. Профильное: алгоритмы и структуры данных, базы данных, ОС, системное программирование.

Проекты

RAG Document Assistant

AI-ассистент для семантического поиска и вопросно-ответной работы по документам пользователя.

- **Стек** — Python, Sentence-Transformers, NumPy, PyPdf.
- Реализовал кросс-языковой векторный поиск и защиту от галлюцинаций через динамический порог релевантности. Защищён как тестовое задание в ИТ-хаб «Северстали».

SUAI Deadline Bot

Асинхронный Telegram-бот для отслеживания дедлайнов в ЛК ГУАП; 100+ активных студентов ежедневно.

- **Стек** — Python, asyncio, Aiogram 3.x, SQLAlchemy 2.0 (async), Alembic, Docker.
- Спроектировал схему БД и фоновый парсинг с обработкой отказов внешнего сервиса. Настроил CI/CD: тесты, сборка образа в GHCR, автодеплой на продакшен-сервер.

Навыки и инструменты

Языки программирования: Python, SQL, Bash, C/C++, Assembler

Бэкенд: FastAPI, asyncio, Pydantic, SQLAlchemy 2.0 (async), Alembic, PostgreSQL, SQLite, REST API, Swagger/OpenAPI

AI/LLM: RAG, промпт-инжиниринг, эмбеддинги, чанкинг, векторные БД (Qdrant, pgvector), self-hosted инференс (vLLM, Triton), LangChain, n8n, OpenAI API, Sentence-Transformers, NumPy

Инфраструктура: Docker, Docker Compose, Linux, Git, CI/CD (GitHub Actions, Jenkins), Jira, Confluence

Тестирование: PyTest, unit- и smoke-тесты, тестирование API (Postman, Swagger)

Базовый уровень: PyTorch, Hugging Face, Kubernetes, Nginx, Prometheus/Grafana

Языки: Русский — родной, Английский — B2 (Upper-Intermediate)